

SAE Description et Prédiction de séries temporelles

RAPPORT DE PROJET : Analyse et Prédiction de la série temporelle "Diarrhée aiguë"

Formation : BUT SD - IUT de Paris - EMS-FI

Module : SAE Description et Prédiction de séries temporelles

Auteurs : Laïd-Ayman NAÏMI & Anthony EL DAHDAH

Date : 16 Décembre 2025

Sommaire

I. Description et préparation des données

1. Source et Indicateur utilisé
2. Traitement des données

II. Analyse de la série temporelle

1. Analyse générale
2. La série temporelle brute
3. La tendance
4. La moyenne mobile
5. Les coefficients saisonniers
6. La série désaisonnalisée
7. Les résidus

III. Prévision et évaluation

1. La régression polynomiale
2. ARIMA
3. ETS
4. Conclusion

IV. Annexe

1. Répartition des tâches
 2. Résumé
-

Introduction

L'épidémiologie occupe une place centrale dans la surveillance de l'état de santé des populations, en particulier pour le suivi continu des maladies infectieuses en médecine de premier recours.

En France métropolitaine, le réseau Sentinelles constitue le dispositif de référence, s'appuyant depuis 1984 sur un ensemble de médecins généralistes et pédiatres pour collecter de manière régulière des indicateurs épidémiologiques clés, permettant d'évaluer l'évolution des affections courantes et d'anticiper les dynamiques épidémiques.

Cependant, au fil des dernières années, l'indicateur de diarrhée aiguë a montré des variations particulièrement marquées, rendant nécessaire une analyse plus approfondie de son évolution.

C'est pourquoi, dans cette étude, nous nous concentrerons sur l'indicateur de diarrhée aiguë, l'un des signaux surveillés en continu par le réseau depuis 1991.

L'objectif de notre analyse est d'examiner les tendances observées dans les données de diarrhée aiguë pour mieux comprendre les fluctuations saisonnières, les épisodes d'augmentation inhabituelle de l'incidence, ainsi que les éventuelles modifications de la dynamique épidémiologique.

I. Description et préparation des données

1) Source et Indicateur

Les données utilisées proviennent du site officiel du réseau Sentinelles et concernent la diarrhée aiguë. Celle-ci y est définie comme : « *au moins trois selles liquides ou molles par jour, évoluant depuis moins de 14 jours et motivant la consultation* ».

Le fichier regroupe environ **2 000 observations** et **10 variables** :

- **week** : année et numéro de semaine
- **indicator** : numéro de l'indicateur suivi
- **inc** : incidence estimée*
- **inc_low** : borne basse de l'incidence
- **inc_up** : borne haute de l'incidence
- **inc100** : incidence rapportée pour 100 000 habitants
- **inc100_low** : borne basse correspondante
- **inc100_up** : borne haute correspondante

- **geo_insee** : code du territoire (ex. : « fr »)
- **geo_name** : nom du territoire

* *l'incidence d'une maladie est le nombre de nouveaux cas de cette maladie observés sur une période donnée*

2) Traitement des données


Avant de procéder à l'analyse, une phase de traitement des données a été nécessaire. Plusieurs transformations ont été réalisées :

1. Création de deux variables distinctes : l'année et le numéro de semaine, à partir de la variable *week*.
2. Génération d'une variable "mois" dérivée du numéro de semaine.
3. Construction de classes quinquennales (par tranches de cinq ans, ex. : 1990–1994).
4. Conversion des variables numériques au bon format à l'aide de `as.numeric`.

II. Analyse de la série temporelle


1) Analyse générale

Le graphique ci-dessous présente l'évolution de l'inc100 selon les différentes tranches quinquennales. On constate une augmentation marquée entre 1990 et 2009, suivie d'une diminution progressive au fil des périodes suivantes, jusqu'à une baisse nettement plus prononcée sur 2025-2029. Toutefois, cette dernière période n'étant pas encore complète, les valeurs observées doivent être interprétées avec prudence.



2) La série temporelle brute

Ce graphique montre l'évolution brute de l'incidence de la diarrhée aiguë sur plus de trente ans, avec une saisonnalité marquée et des pics hivernaux réguliers. On observe une période de forte intensité entre 2000 et 2010, suivie d'une baisse progressive, puis d'une chute nette à partir de 2020, où le niveau et l'amplitude des épidémies diminuent fortement. Ce graphique est utile pour justifier les analyses suivantes : il montre clairement la nécessité de désaisonnaliser la série pour étudier la tendance de fond.



Expression de la série temporelle brute :


$$Y_t = T_t \times S_t \times E_t,$$

où Y_t est la valeur observée à l'instant t ,
 T_t est la tendance,
 S_t la saisonnalité,
 E_t le résidu

3) La tendance

Le graphique montre la tendance de fond de l'incidence, obtenue après avoir retiré les variations saisonnières et le bruit grâce à la décomposition STL. La courbe rouge illustre l'évolution entre 1990 et 2026 : forte hausse dans les années 1990, plateau élevé entre 2000 et 2010 autour de 150 à 200, puis baisse régulière à partir de 2010. En 2020, on observe une chute brutale vers un minimum historique, suivie d'une stabilisation à un niveau bas et d'une remontée en fin de période. Ce graphique permet de visualiser clairement la dynamique de long terme, en filtrant les pics saisonniers. Il montre que le recul de l'épidémie avait commencé

avant 2020 et que la reprise à la fin de la série pourrait signaler un retour à des niveaux plus élevés dans les années à venir.




Expression de la tendance :

$$T_t = a_0 + a_1t + a_2t^2 + \dots + a_nt^n,$$

où T_t est la tendance déterministe au temps t ,
 $a_0, a_1, \dots, a_n$ sont les coefficients du polynôme,
 t est la variable temporelle,
 n est le degré du polynôme.

4) La moyenne mobile

Le graphique présente l'évolution de l'incidence de la diarrhée aiguë après lissage par moyenne mobile. La courbe violette conserve les pics hivernaux caractéristiques tout en réduisant les variations irrégulières à court terme. La dynamique générale reste la même que dans les données brutes : montée progressive dans les années 1990, pic soutenu entre 2000 et 2010, puis baisse régulière jusqu'en 2020. La rupture de 2020 est nette, avec un effondrement suivi d'un maintien à un niveau très bas et de cycles saisonniers atténués en fin de période. Ce graphique sert d'étape intermédiaire entre la série brute et la tendance de fond.



Expression de la Moyenne Mobile :


$$MM_t = \frac{1}{k} \sum_{i=-(k-1)/2}^{(k-1)/2} Y_{t+i},$$

où MM_t est la moyenne mobile centrée au temps t ,
 Y_{t+i} sont les valeurs observées, et k l'ordre de la moyenne.

Dans notre cas, nous avons choisi $k = 3$ afin de suivre de près les variations, ce qui est particulièrement important dans une perspective épidémiologique, en limitant au maximum le lissage.

5) La série désaisonnalisée

Le graphique superpose la série désaisonnalisée (bleue) et la tendance de fond (rose). La courbe bleue, après retrait de la saisonnalité, reste très irrégulière avec des pics marqués, notamment au début des années 2000. La courbe rose, plus lisse, suit ces variations et montre l'évolution générale : un niveau élevé jusqu'en 2010, une baisse progressive ensuite, puis une chute nette en 2020, marquant une rupture importante. Ce graphique permet de visualiser ce qui subsiste de l'épidémie une fois l'effet hivernal retiré, d'identifier les fluctuations exceptionnelles et de montrer que les variations d'intensité ne sont pas uniquement saisonnières mais aussi liées à des facteurs ponctuels ou biologiques. Il confirme également que la baisse de 2020 correspond à un effondrement réel du niveau de base de la maladie.




Expression de la saisonnalité :

$$S_t = \frac{Y_t}{T_t},$$

où S_t est la composante saisonnière relative au temps t .

6) Les coefficients saisonniers

Ce graphique montre les coefficients saisonniers hebdomadaires, c'est-à-dire l'influence de chaque semaine sur l'incidence de la diarrhée aiguë par rapport à la moyenne annuelle. Le profil en U confirme la forte saisonnalité observée entre 1990 et 2025 : l'incidence est maximale en début et fin d'année (semaines 50 à 5, coefficient $\sim 2,5$), soit deux fois et demie la moyenne, et minimale en été (semaines 18 à 30, coefficient $\sim 0,6$), quatre à cinq fois plus faible qu'en hiver. Ce schéma explique la formation des pics annuels visibles dans la série chronologique brute.




Expression des coefficients saisonniers :


$$S_s = \frac{1}{n_s} \sum_{t \in \text{saison } s} \frac{Y_t}{T_t},$$

où n_s est le nombre d'observations pour la saison s ,
 Y_t les valeurs observées, et T_t la tendance.

7) Les résidus

On observe d'abord les résidus par semaine, mais pour une analyse plus claire, on se concentre sur les résidus agrégés par mois. Le graphique mensuel les représente sous forme de boîtes à moustaches, avec les mois en abscisse et l'amplitude des erreurs en ordonnée. La médiane reste proche de zéro tout au long de l'année, montrant l'absence de biais saisonnier. La dispersion, en revanche, varie selon la saison : les boîtes sont compactes en été, indiquant une bonne précision lorsque l'incidence est faible, tandis qu'en hiver elles s'étendent davantage et présentent de nombreux points extrêmes, révélant que le modèle commet ses plus grandes erreurs lors des pics épidémiques.





Expression des résidus :


$$E_t = \frac{Y_t}{T_t \times S_t},$$

où E_t est le résidu au temps t .

III. Prévision et évaluation

Nous allons comparer trois modèles de prévision afin d'évaluer leur capacité à anticiper les tendances futures de la diarrhée aiguë pour les 40 semaines de 2025, en prenant les données jusqu'à 2024 en guise d'entraînement. Et nous calculerons leur EQM (Erreur Quadratique Moyenne) pour déterminer le meilleur modèle.


Prévisions 40 semaines de 2025 : ARIMA / ETS / Polynomiale



1) La régression polynomiale

Le graphique compare les données réelles d'incidence (noir) aux prévisions du modèle de régression polynomiale (vert) pour la période de test de 2025. La courbe verte, très lisse, ne reflète pas la volatilité de la courbe noire : elle lisse complètement les variations hebdomadaires et produit un pic trop étalé, incapable de représenter la poussée épidémique réelle. Ce graphique montre les limites de la régression polynomiale pour ce type de données : trop rigide, le modèle ne capture pas la dynamique rapide d'une épidémie virale. L'erreur élevée (RMSE de 38,44) confirme que le modèle simplifie trop l'information, perdant ainsi la précision nécessaire pour une surveillance sanitaire efficace.

Régression Poly. - Prévisions (RMSE: 37)



$$\hat{y}_t^{(p)} = \hat{a} + \hat{b}t + \hat{c}t^2 + \hat{s}_t,$$

où $\hat{y}_t^{(p)}$ est la valeur prédite au temps t ,


$\hat{a}$, $\hat{b}$, $\hat{c}$ sont les coefficients estimés de la régression polynomiale,

t est la variable temporelle,

$\hat{s}_t$ est la composante saisonnière estimée.

2) ARIMA

Le graphique compare les valeurs réelles d'incidence (noir) aux prévisions du modèle ARIMA (rouge) pour la période de test 2025, avec le taux pour 100 000 habitants en ordonnée et les semaines en abscisse. La courbe rouge suit bien la tendance générale lors des périodes calmes (semaines 35.2 à 35.7), mais lors du pic brutal vers la semaine 35.8, le modèle réagit avec un léger décalage et une intensité excessive : le pic prédit est plus haut et légèrement retardé avant de redescendre. Ce graphique montre que l'ARIMA capte la tendance globale (RMSE de 34,19) mais a du mal à reproduire exactement la synchronisation et l'amplitude des pics.



$$\hat{Y}_t = \mu + \phi_1 Y_{t-1} + \dots + \phi_p Y_{t-p} - \theta_1 \varepsilon_{t-1} - \dots - \theta_q \varepsilon_{t-q},$$

où $\hat{Y}_t$ est la prévision à l'instant t ,

$\phi_1, \dots, \phi_p$ sont les coefficients autorégressifs (AR),

$\theta_1, \dots, \theta_q$ sont les coefficients de moyenne mobile (MA),


d est l'ordre de différenciation pour rendre la série stationnaire,

ε_t les résidus blancs.

3) ETS

Le graphique compare les données réelles d'incidence (noir) aux prévisions du modèle ETS (bleu) pour la période de test 2025, avec le taux d'incidence en ordonnée et les semaines en abscisse. La courbe bleue suit fidèlement la courbe noire durant les phases stables et réagit immédiatement au pic épidémique après la semaine 35.6, reproduisant la montée avec précision et atteignant le sommet au même moment que la réalité. Ce graphique montre la supériorité de l'ETS par rapport aux autres modèles : il capture parfaitement le timing et la forme de l'épidémie, contrairement à la régression polynomiale qui lisse trop ou à l'ARIMA qui décale le pic. La RMSE la plus faible (26,95) confirme que c'est le modèle le plus fiable pour alerter les autorités sanitaires, tout en restant légèrement prudent sur l'ampleur du pic.

ETS - Prévisions (RMSE: 26.95)



$$\hat{Y}_{t+h} = l_t + b_t \cdot h + s_{t+h-m},$$

où l_t est le niveau au temps t ,
 b_t la tendance,
 s_{t+h-m} la saisonnalité ajustée pour la période de prévision h ,
 m étant la périodicité de la saisonnalité (ex : 12 pour données mensuelles).

4) Conclusion meilleure modèle



En conclusion, le modèle **ETS** se révèle le plus performant : il reproduit fidèlement la dynamique et le timing des pics épidémiques avec **la plus faible erreur**, offrant ainsi la prévision la plus fiable pour la surveillance sanitaire.

Annexe

1) Répartition des tâches

	Partie 1	Partie 2	Partie 3	Rédaction du rapport	Résumé
NAIMI		X	X	X	
EL DAHDAH	X	X			X

2) Résumé

In this project, we analyzed the time series of acute diarrhea incidence in mainland France using weekly data from the Sentinelles network, covering a period of more than 30 years.

We first focused on preparing the data. This included cleaning the dataset, separating the year, week, and month variables, and grouping the years into five-year periods. These steps helped make the data easier to read and ensured that the analysis was reliable.

Next, we studied the time series itself. The raw data clearly showed a strong seasonal pattern, with higher incidence during winter and lower levels in summer. By decomposing the series into trend, seasonality, and residuals, we were able to better understand the long-term behavior of the disease. The results showed an increase from the 1990s until around 2010, followed by a gradual decline and a sharp drop around 2020.

Finally, we compared three forecasting models: polynomial regression, ARIMA, and ETS. Their performance was evaluated using the RMSE criterion. Among the three, the ETS model gave the best results, as it accurately captured both the timing and the size of epidemic peaks. For this reason, ETS appears to be the most appropriate model for predicting acute diarrhea incidence and supporting public health monitoring.